

կօթն

**גניזה ואיסתור - איסתור כבשון כלו.** אף כי גניזה הינה מושג של ימי קדום, מושג זה מתייחס לזמן מודרני.

\***አምነት ከያንስ ማዕከል (Unsupervised)** - የዚህ ማኅጂዥ ስራውን / በፊልግ ይገልጻል፡ ይገልጻል፡ የዚህ ማኅጂዥ ከዚህ ማኅጂዥ ነው፡ ይገልጻል፡ የዚህ ማኅጂዥ ከዚህ ማኅጂዥ ነው፡ ይገልጻል፡

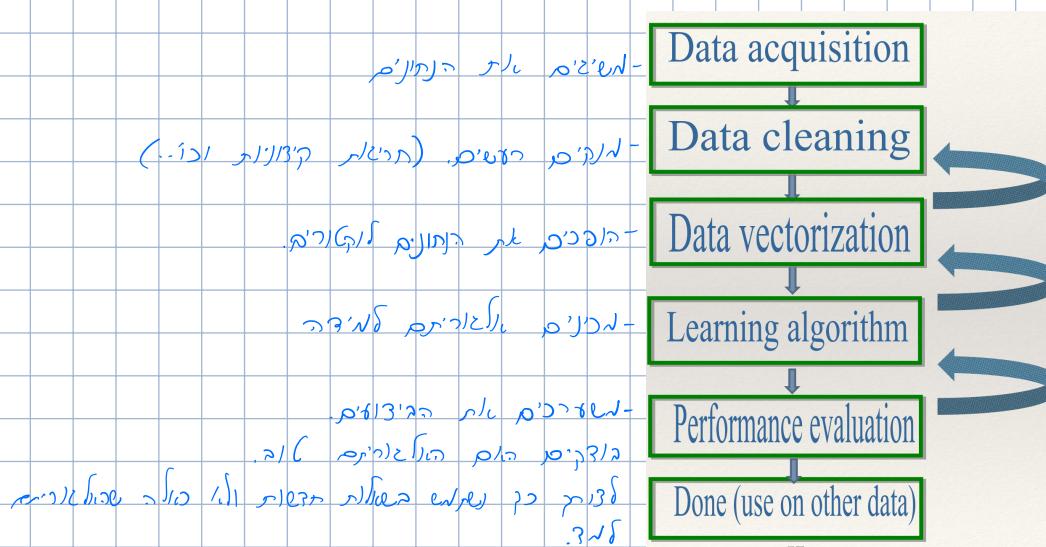
- የተለያዩ አገልግሎቶች መካከል የሚሰጥ ይችላል፡ የሚለውን ደንብ በመሆኑ የሚሰጥ ይችላል፡
- ምንም የሚለውን ደንብ መካከል የሚሰጥ ይችላል፡ የሚለውን ደንብ በመሆኑ የሚሰጥ ይችላል፡

**Clustering • የሚለውን ደንብ የሚሰጥ ይችላል፡ (ጥቅምት/ወርፍ)**

כ. סעיפים ג) דיביגו צי היבר. ג) קבוצת רפואים ו- כ. קבוצת מזון. נ. קבוצת מזון.

\* מילוי טבלה: רהיבת פוליאקס בעקבות (רשותן) ותפקידם כהוותה בקשר לתקינות. 

\* מילוי טבלה: 1. סדרה (Classification) 2. נסיגה (Regression) 3. קבוצתית (Clustering)



# النحو والصرف

האם זו היא מטרתך? ומי שיכתב לך?

• Feature Vector -  $\vec{x}$  will be called **Raw Data**  $\otimes$

• Multiclass: 2-1  $\rightarrow$  Binary = 2 classes

•  $\vec{x}_i$   $\in \mathbb{R}^n$   $\rightarrow$   $x_i$  is the **Attribute** (Feature)  $\otimes$   $\vec{x}_i$  is the **Predictor** (Predict)

הנושאים הנדרשים לשלב מנגנון ה-Feature Engineering (Feature Engineering) הם:

Instance  $\vec{x}$  (vector of features)  $\rightarrow$  Feature Vector  
 Feature Set  $\{x_1, x_2, \dots, x_n\}$   $\rightarrow$  Feature Set  
 Label  $y$   $\rightarrow$  Supervised

↳ **Dataset**:  $\{x_i\}_{i=1}^n$   $x_i \in \mathbb{R}^d$   $y_i \in \mathbb{R}$

המודל מתאר (Modeling) מושג אחד

(ج) تجزیه و تحلیل (ج) تجزیه و تحلیل

(15/15) הינה יפה נושא למשך זמן רב.

(Data Aquisition)  $\rho_{\text{H}_2\text{O}} = 1$

200 p. 21- Cleansing → 83-N. 212-6. 2

2)  $\frac{1}{2}$

תפקידו של מילר כהנמן (1963) היה לסייע לאנתרופולוגים בפיזיון ופונטונטוניה.

Data Engineering → Feature Extraction → Vectorization ↗clip 65 → Instance m' 3

הניעו מושגיהם הדרומיים מארץ התיכונית שלהם, איה הרים רכילים

## Feature Selection

הجزן הראשון יתרכז במבנה חישובים (Computing) ופונקציית חישובים (Computing Function). בפונקציית חישובים (Computing Function) ישנו מושג Instance, כלומר, מושג אחד או יותר של הפעולה (הפעולה שפונקציית חישובים מבצעת) ברגע מסוים. מושג Instance מוגדר כ-Object (Object) או Object State (Object State).



כדי לארוך גווניות מודולריזציה, נשים בפניהם מינימום ומקסימום. **min-max normalization**

(ג) מילוי מסמך החלטה על סכום גיורא (בהתאם לתקנון).

$$2 \cdot 1 - 1 = 1 \quad -1 \quad 2 \cdot 0 - 1 = -1 \quad .1 \quad , 0, 1 \quad 2 - 2 \quad [0, 1] \quad [0, 1] \rightarrow \text{Interval} : [-1, 1]$$

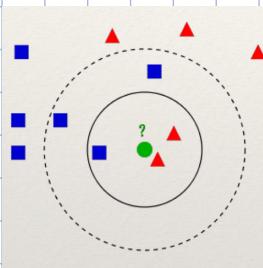
בנוסף לשליטה על הרכבת, מטרת המלחמה הייתה לכבוש את אזור ים המלח ונהר הירדן.

# Classification & KNN

האלגוריתם KNN מושג באמצעות סט נתונים (Training) ו-Scaling. סט נתונים הנקרא (Majority) מושג באמצעות סט נתונים (Testing). סט נתונים הנקרא (Testing) מושג באמצעות סט נתונים (Training) ו-Scaling.

**KNN**( $x, k$ ):  
 for each train instance  $x_i$  in train-set do:  
 add  $\text{distance}(x_i, x)$  to  $D$   
 $k\text{Nearest} \leftarrow$  Select  $k$  shortest distances from  $D$  (e.g.  $D$  sorted)  
 return major classification (majorityVoting) from  $k\text{Nearest}$

לעתה נ训ר train-set על מנת לearn את ה- model. test-set יתפקיד test instance. מטרת ה- model היא לpredict את ה- label.



2. כב. פלטינום (Pt) - מינרל קידמי,  $k=3$ . סולפיטים נטים.

3. מינימום  $f(x) = x^2 + 5x + 6$

1/32 | 10% train-set | 2% test-set

13. الآن لهم أنت جئت بنا عذاباً كبيراً فإن ما جاء بنا إلا عذاباً

Dataset  $\rightarrow$  Train and Test  $\otimes$   
(训集)  $\rightarrow$  Train-set 1  
(测试集)  $\rightarrow$  Test-set 2

The figure consists of three side-by-side diagrams. Each diagram shows a 3x3 grid of points labeled 1 through 9. A specific point is highlighted in orange.

- Manhattan Distance:** The distance between the orange point and the top-left corner (1) is calculated as the sum of the horizontal and vertical distances:  $|x_1 - x_2| + |y_1 - y_2|$ .
- Euclidean Distance:** The distance between the orange point and the top-left corner is the straight-line distance:  $\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$ .
- Chebyshev Distance:** The distance between the orange point and the top-left corner is the maximum of the absolute differences in the x and y directions:  $\max(|x_1 - x_2|, |y_1 - y_2|)$ .

$D_{ab} \geq 0$  .  $\therefore$   $D$  is  $\geq 0$ .

$$D_{ab} = D_{ba} \quad \text{ריבוע מטריצת דיפרנציאלי}$$

$Daa = 0$  : 138 נס

$$\text{P} = 1 \cdot \left( \sum_{i=1}^n |x_i - y_i| \right)^p$$

$$\text{rank } p = 2$$

$$3 \quad \gamma \approx 1 \quad p = \infty \quad .$$

6

לעת נסעה הרכבת מארה (הרכבת הירקון) לכיוון יפו.

$$\text{Time} \geq \omega(n) \quad \{ \quad K = O(\sqrt{n})$$

• The following table shows the results of a study on the relationship between the number of hours spent studying per week and the final exam scores for a group of students.

\_\_\_\_\_

המבחן ק נכון למדן. מבחן טמיון הנקודות (בגראונט) גודל k כ-0.5%.

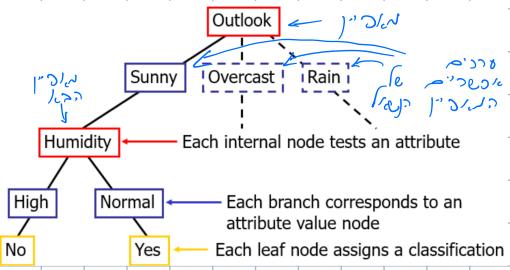
לכל  $k \in \mathbb{N}$ ,  $\sum_{i=1}^k \frac{1}{i^2} < \frac{\pi^2}{6}$ .

בכינור פועל מכך, נסחוג כי רצח גנדי היה מעוות מילוי.

ANSWER

# Decision Trees

⊗ כבש: גזרת פונקציה כפולה של גזרת סינוס כפולה נוגע  
- בפונקציה ריבועית של גזרת סינוס כפולה (סינוס ריבועי)



לפניהם נסמן  $\text{NN}_k$  ומכירם  $\text{G}_k$  כראוי.

Training Set Error:  $\text{Error}_{\text{Training Set}} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$

$$H(x) = - \sum_{i=1}^n p(x_i) \cdot I(x_i) = - \sum_{i=1}^n p(x_i) \cdot \log(p(x_i))$$

$$H(x) = \sum_{i=1}^n p(x_i) \cdot I(x_i) = -\sum_{i=1}^n p(x_i) \cdot \log(p(x_i))$$

- \*10) כוונת ה- $H(Y|X=x)$  - מילוי שרטוט ה- $H(Y|X=x)$ .
- 9) כוונת ה- $H(Y|X)$  - מילוי שרטוט ה- $H(Y|X)$ .
- 8) כוונת ה- $H(Y|X=x_0)$  - מילוי שרטוט ה- $H(Y|X=x_0)$ .
- 7) כוונת ה- $H(Y|X=x_1)$  - מילוי שרטוט ה- $H(Y|X=x_1)$ .
- 6) כוונת ה- $H(Y|X=x_2)$  - מילוי שרטוט ה- $H(Y|X=x_2)$ .
- 5) כוונת ה- $H(Y|X=x_3)$  - מילוי שרטוט ה- $H(Y|X=x_3)$ .
- 4) כוונת ה- $H(Y|X=x_4)$  - מילוי שרטוט ה- $H(Y|X=x_4)$ .
- 3) כוונת ה- $H(Y|X=x_5)$  - מילוי שרטוט ה- $H(Y|X=x_5)$ .
- 2) כוונת ה- $H(Y|X=x_6)$  - מילוי שרטוט ה- $H(Y|X=x_6)$ .
- 1) כוונת ה- $H(Y|X=x_7)$  - מילוי שרטוט ה- $H(Y|X=x_7)$ .

$$Gain(Y|X) = H(Y) - H(Y|X)$$

Information Gain \*  
 $H(Y) = -\sum p_i \log_2 p_i$

(54 8<sub>pe</sub>, 3 831 : 7w(12)

**BuildTree(*TrainSet*, *Output*)**

- ❖ Termination Recursion cases:
  - ❖ (Base case 1) If all output values are the same in *DataSet*, return a leaf node that says “predict this unique output”
  - ❖ (Base case 2) If all input values are the same, return a leaf node that says “predict the majority output”
  - ❖ Otherwise (not recursion termination case) – find attribute X with the highest score - *highest Info Gain / lowest conditional entropy*
  - ❖ Suppose X has  $n_X$  distinct values (i.e. X has arity  $n_X$ ).
    - ❖ Create and return a non-leaf node with  $n_X$  children.
    - ❖ The  $i$ 'th child should be built by calling

`BuildTree( $TS_i$ , Output)`

Where  $TS_i$  built consists of all those records in  $TrainSet$  for which  $X = i$ th distinct value of  $X$ .

בנוסף ל-טראנספורמציית גזים, מתקיימת טראנספורמציית גזים בטראנספורמציית גזים.

## Confusion matrix:

Test -1 Train - $\{f_i\}$ , Dataset - $\rightarrow$ : Evaluation - $p(\gamma)$  

	Predicted Yes	Predicted No
Actual Yes	True Positive (TP)	False Negative (FN)
Actual No	False Positive (FP)	True Negative (TN)

אכלה מכם תרנגולת ורין, ורין תרנגולת אכלה.

$$\text{accuracy} = \frac{\# \text{TP} + \# \text{TN}}{\# \text{ of test instances}} \quad - \text{P1.3} -$$

בנין גוף כירור, מודול או מודול גוף כירור.

$$\text{error rate} = \frac{\#FP + \#FN}{\# \text{ of test instances}} - \text{1 - accuracy}$$

test -> 1 <--> 2 <--> 3 <--> 4 <--> 5 <--> 6 , Trainset -&

•  $\text{Error}_{\text{train}}(h)$  •

(D)  $\text{m}(x)$  :  $\rho$  (m)  $\|f\|_2^2$  h (e)  $\rho$  (m) - Error<sub>0</sub>(h)

Overfitting ->  $\sigma^2$   $\approx$  0

לולק את קבוצת האמנים לקובזת "ציירת עץ" וקובוצת "תיקוף" (validation)

- ❖ צור עץ החלטה – תוך שימוש בקובוצת "יצירת עץ"  
 ❖ שלב קיצוץ בדיעבד – בעז כל מון שלא נפגעים הביצועים יותר  
 ❖ עברו כל צומת פמייניו (לא שורש) בצע  
 ❖ קפז את העץincl. של צומת זה (היפיכת האותיות לעלправ) – ההחלטה עברו צומת זה לפי הגביעת רוח בתה-הען שלו  
 ❖ בהן ביצועי תreen הפלטץ על קובצת התרחק והשווינו בweisums לעצם הלא-מקווצה  
 ❖ באופו המכני ביצ' צומת עם הרוחה הדגול בטור

## Naive Bayes

62% - Bp1

$$P(c|x) = \frac{P(x|c) \cdot P(c)}{P(x)}$$

לפניהם נסמן סימן  $\otimes$  ו- $\oplus$  (בנוסף ל- $\ominus$  ו- $\oplus$ )

בהתאם לה从前知识 -  $P(c)$  (prior)  
ובהתאם לה證據 -  $P(x|c)$  (likelihood)

ההיפות  $\text{de}$  מושגית -  $p(x)$  (evidence)

-  $p(c|x)$  (posterior)

\* $\forall x \exists y \forall z (P(x) \wedge P(y) \wedge P(z) \rightarrow x = y \wedge x = z)$

ההסתברות  $P(A \cap B)$  היא  $P(A) \cdot P(B)$

$$P(x_1 = u_1, x_2 = u_2, \dots, x_n = u_n) = \prod_{i=1}^n P(x_i = u_i)$$

$$P(c | x_1, x_2, \dots, x_n) = \frac{P(x_1, x_2, \dots, x_n | c) \cdot p(c)}{P(x_1, x_2, \dots, x_n)}$$

$$P(x_1, x_2, \dots, x_n | c) = \prod_{i=1}^n P(x_i | c)$$

- Train Naïve Bayes (given data for X and Y)

for each value  $y_k$

$$\text{estimate } \pi_k \equiv P(Y = y_k)$$

for each value  $x_{ij}$  of each attribute  $X_i$

$$\text{estimate } \theta_{ijk} \equiv P(X_i = x_{ij} | Y = y_k)$$

- Classify ( $X^{new}$ )

$$Y^{new} \leftarrow \arg \max_{y_k} P(Y = y_k) \prod_i P(X_i^{new} | Y = y_k)$$

$$Y^{new} \leftarrow \arg \max_{y_k} \pi_k \prod_i \theta_{ijk}$$

\* probabilities must sum to 1, so need estimate only n-1 of these...

Underflow - נספחים למספרים קטנים מ-1. מילוי ב-0.00000...  
 $\log\left(\prod_{i=1}^n P(x_i | y_k)\right) = \sum_{i=1}^n \log(P(x_i | y_k))$

Confusion matrix:

		Recall	Precision
		Predicted Yes	Predicted No
Actual Yes	True Positive (TP)	False Negative (FN)	
Actual No	False Positive (FP)	True Negative (TN)	

: Precision & Recall

$$\text{Precision} = \frac{\#TP}{\#TP + \#FP}$$

$$\text{Recall} = \frac{\#TP}{\#TP + \#FN}$$

Dataset -  $P(X=x | Y=y)$  הינה סבבון סטטיסטי סמוי (Smoothing)

$$P(X=x | Y=y) = \frac{n_c + m \cdot \rho}{n + m}$$

dataset  $m \rightarrow$  prior  $X=x$  גודל הסטטיסטי  $n$  גודל הסטטיסטי  $m$

$(\mu, \sigma^2)$  פונקציית הסתברות נורמלית  $f(x | \mu, \sigma^2)$

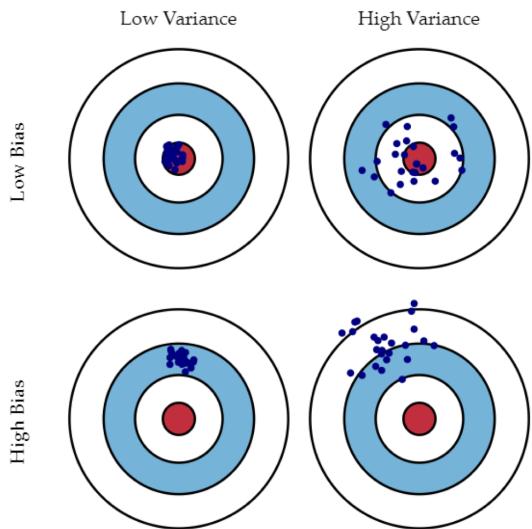
$$P(X=x | Y=y) = \frac{1}{\sigma \sqrt{2\pi}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\mu = \frac{1}{N} \cdot \sum_{i=1}^N x_i$$

$$\sigma = \sqrt{\frac{1}{N-1} \cdot \sum_{i=1}^N (x_i - \mu)^2}$$

$$f(x | \mu, \sigma^2) = \frac{1}{\sigma \sqrt{2\pi}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

# ML Flow Dive



Interquartile Range  $\times$

$$IQR = Q_3 - Q_1$$

$$Q_1 = \frac{1}{2} \sum_{i=1}^{n/2} x_i, \quad Q_3 = \frac{1}{2} \sum_{i=n/2+1}^n x_i$$

$IQR = Q_3 - Q_1$

Outliers  $\times$

(x̄, ȳ) = (μ<sub>x</sub>, μ<sub>y</sub>)

$$\text{Pearson} = \rho(x,y) = \frac{\text{Cov}(X,Y)}{\sigma_x \cdot \sigma_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

$$\begin{aligned} I(X;Y) &\equiv H(X) - H(X|Y) \equiv \\ &\equiv H(Y) - H(Y|X) \equiv \\ &\equiv H(X) + H(Y) - H(X,Y) \equiv H(X,Y) - H(X|Y) - H(Y|X) \end{aligned}$$

High Correlation to Target -  






## Feature Selection & Dimensionality Reduction

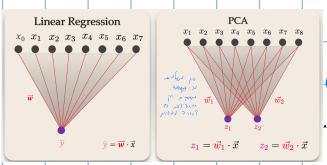
## 2. Feature Selection

הנתקה מהתבוננות על הנקודות ופיזורן במרחב, ופונה למדידת אמצעי וטיפות. תבוננה זו נקראת **Feature Extraction**.

**אנו יגנץ:** נשים כוחן מילר ג'רי גאנט  
-מכוער כהר נשים כהן כהן ליבור קומלון.

$\vec{z} = \vec{\omega} \cdot \vec{x}$  מינימיזציה של הבדן בין פונקציית ג'ייגר ופונקציית האנרגיה: (Principal Component Analysis) PCA  $\otimes$

לפנינו קיימת אוסף נתונים  $\vec{x} = (x_1, x_2, \dots, x_d)$  לאUPERVISED. קיימים  $K$  וקטורים מאובטחים  $\vec{\omega}_1, \vec{\omega}_2, \dots, \vec{\omega}_K$  שמייצגים את המרכיבים הראשיים. מטרת הPCA היא למצוא מרכיבים ראשיים  $\vec{\omega}_1, \vec{\omega}_2, \dots, \vec{\omega}_K$  כך שפונקציית האנרגיה  $\vec{z} = (\vec{\omega}_1 \cdot \vec{x}, \vec{\omega}_2 \cdot \vec{x}, \dots, \vec{\omega}_K \cdot \vec{x})$  תהיה מינימלית.



ב- $\lambda_1 + \lambda_2 + \dots + \lambda_k$  מוגדרת כ- $\lambda_1 + \lambda_2 + \dots + \lambda_d$ . נסמן  $\lambda = \lambda_1 + \lambda_2 + \dots + \lambda_d$ .

(NaN וnull מוגדרים כאוֹטליירס, PCA שמייצג אוניברסיטאות מוגדר.)

\* PCA نونين عرضها target (goal) كالى يجيء من Numeric -

# Clustering & K-means

לפניהם נסמן  $\{X_i, y_i\}$  - סט נתונים (X-טכני, Y-טכני).

**מיצוי נוילר:** כר הרכבת מרכז כלאה גן גון גן הפלדה ו. קיון כר {; X}

השאלה מושגית (1) נספחים ל-**Partitioning** - חלוקה: החלטה על קבוצות נספחים (2) שילוט היררכי: גזם מפוזר כירכתי (3) נספחים בפיזיק (Density): מתחם מוגדר, רגילים בין רקען, גודל מלהתק (4) הסטראט, ארכיטקט: מוחץ תרבות משלמה ותפקידו (5) גזם אינטלקטואלי או טכנולוגית (6) גזם טכנולוגיות עולמי.

(center)  $C \propto$  (mean)  $\mu$   $\Rightarrow$   $f(\mu) = \sum_{i=1}^n d(x_i, \mu)$   $\mu_1, \dots, \mu_k$   $\Rightarrow$   $\mu$ -prototype  $\Rightarrow$   $\mu_1, \dots, \mu_k$   
 מינימום  $d(\mu)$   $\Rightarrow$   $\mu$ -prototype  
 $d(x_i, \mu) = \|x_i - \mu\|^2$   
 $f(\mu) = \min \sum_i d(x_i, \mu)$   $\Rightarrow$  מינימום  $f(\mu)$   $\Rightarrow$  מינימום  $f(\mu)$   $\Rightarrow$  מינימום  $f(\mu)$   $\Rightarrow$  מינימום  $f(\mu)$

<p>פונקציית מינימוקובסקי:</p> $d(\vec{x}_j, \vec{x}_i) = (\sum_{m=1}^d  x_{j_m} - x_{i_m} ^p)^{\frac{1}{p}}$ <ul style="list-style-type: none"> <li>▪ מרחק מינימוקובסקי:</li> <math display="block">d(\vec{x}_j, \vec{x}_i) = \sum_{m=1}^d  x_{j_m} - x_{i_m} </math> <li>▪ מרחק מהותן:</li> <math display="block">d(\vec{x}_j, \vec{x}_i) = \max_{1 \leq m \leq d}  x_{j_m} - x_{i_m} </math> </ul> <p>אפשרויות נוספת:</p> $d(\vec{x}_j, \vec{x}_i) = \frac{\vec{x}_j^T \cdot \vec{x}_i}{\ \vec{x}_j\  \cdot \ \vec{x}_i\ }$ : Cosine similarity	<p>* k-means מתקיים ב-Convex set (באגען):</p> $d(\vec{x}, \vec{y}) = \sqrt{\sum_{i=1}^m (x_i - y_i)^2}$	<p>הרמ' ר' יתנ' ר' (רכ'ך):</p> <ul style="list-style-type: none"> <li>▪ גורם תופסם, כדי שכל נושא כטורי גא. און לוג'נ' = 1.</li> <li>▪ מתק ערך לא נס'ם כט' פא'ם כט' ג'ב'ם כט' ג'ב'ם.</li> </ul>
---	---	--

- **Pre processing** 
- אורי אובי גייגר (Giger) מPROC-ם.
- **Scaling**
- אורי אובי גייגר (Giger) מPROC-ם.
- אורי אובי גייגר (Giger) מPROC-ם.

$$J = \sum_{j=1}^k \sum_{i=j}^n y_{i=j} \sigma_j^2 = \sum_{j=1}^k \sum_{i=j}^n \|x_i - \vec{m}_j\|^2$$

גיאומטרית:  $y_{i=j}$  נסמן כערך של המרחק בין הנקודה  $x_i$  למרכז  $\vec{m}_j$ .

המינימום של פונקציית האפסון מוגדר כערך המינימלי של  $\sum_{i=1}^n \sum_{j=1}^m r_{i,j} \|x_i - x_j\|^2$ .

הצ'רים - מילוי פיזם [מונטג'ו] ו[טבז'ין] כולם נסגרו. (ולא מושג) / (ולא מושג) (ולא מושג)

$J = \text{WSSE}$  = Within Sum of Squared Error :  $\text{WSSE} \rightarrow \text{Jes} \text{ or } \text{Jes}$

Lloyd, 1957 → מינימיזציה של סכום המרחקים מהמרכזים (centroids) ה- $k$  ו-  
 Forgy method, 2002 → מינימיזציה של סכום המרחקים (centroids) ה- $k$  מ-  
 Kmeans++, 2007 ← מינימיזציה של סכום המרחקים (centroids) ה- $k$  מ-  
 גוף אחד.





$tf(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$  term frequency - **tf**  
 $log(1+tf(t, d))$  zipf law -  
 $df(t, D) = \log(\frac{|D|}{|\{d \in D : t \in d\}|})$  document frequency - **df**  
 $\log \cdot t \in d \in D$ : inverse document frequency - **idf**

השאלה מושגית היא שאלת מושגית שפירושה:  $t\text{-tf-idf} - tf\text{-idf}$

$\text{tfidd}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$  . the, and if it's not in our corpus, then we can ignore it.

לעתים קוראים מילון כתוב בפונטיקון, ובקודם מילון כתוב בפונטיקון. מילון כתוב בפונטיקון מילון כתוב בפונטיקון.

Word Vectors: מושג אחד יתפרק למספר מושגים נפרדים. מושג אחד יתפרק למספר מושגים נפרדים.

הארון מוגדר כ $\text{AV} \times \text{AV}$  ומכיל מילים ופונטים כolumnים ושורדים. מטרית上下文 מילויים (Word Context Matrix) היא מטרית שמייצגת מילויים של מילים.

$$PMI = \log_2 \left( \frac{P(x,y)}{P(x) \cdot P(y)} \right)$$

(Pointwise Mutual Information) PMI \*

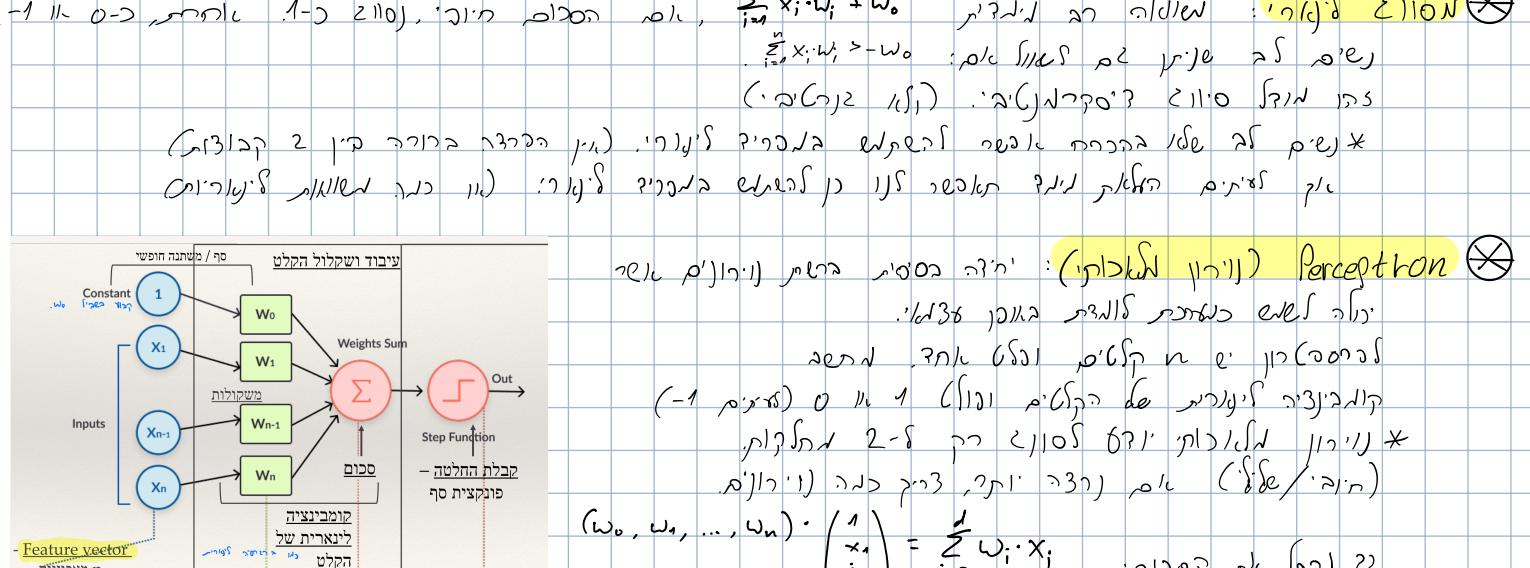
$PPMI = \max(0, PMI)$  where only  $PMI$  is positive measure (Positive  $PMI$ )  $PPMI \neq$

לנתחול למדעי המוח (LSA) (Latent Semantic Analysis) מושג זה מתייחס לניתוח סטטיסטי של טקסטים.

הנושאים הקיימים בPCA ו-LSA הם:

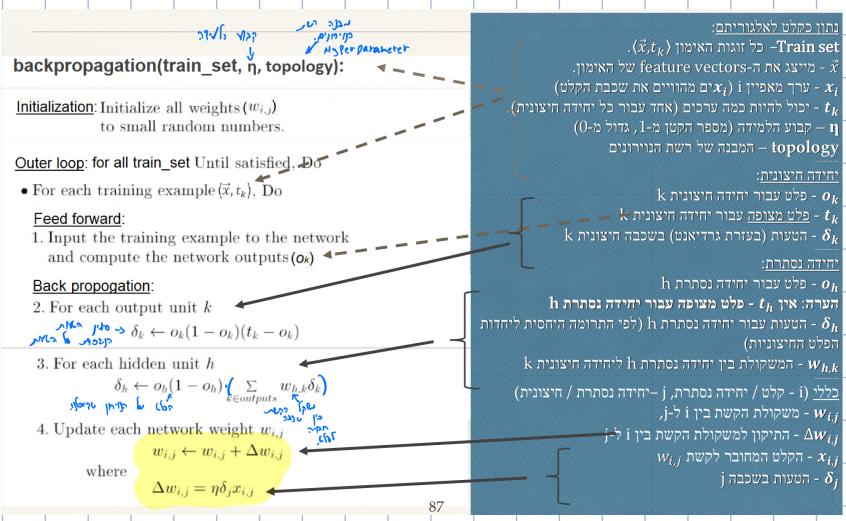
term-matrix • singular-value-matrix • document-matrix (WTF!?)

# ANN - Artificial Neural Networks



$$\text{Sign} = \begin{cases} 1 & \sum_{i=0}^n w_i x_i > 0 \\ -1 & \text{otherwise} \end{cases}$$





לעומת ה-Forward propagation, בBackpropagation מושג המטרה לא רק באמצעות סדרה של אופרציות פונקציונליות, אלא גם באמצעות סדרה של אופרציות דיפרנציאליות. מושג זה מוגדר כפונקציית נזק (loss function), שמייצגת את הבדול בין הפלט המודולר (output) ופלט המטרה (target). אופרציית הדיפרנציאציה שמשתמש בה ב-Backpropagation נקראת gradient descent. מושג זה מוגדר כסדרה של אופרציות דיפרנציאליות, שמייצגות אופרציות דיפרנציאליות של פונקציית הנזק. מושג זה מוגדר כסדרה של אופרציות דיפרנציאליות, שמייצגות אופרציות דיפרנציאליות של פונקציית הנזק.

# Computer Vision

$H \times W$  : Gray

$H \times W \times 3$  : RGB

$[0, 255]$ . p. 16

רְגִזָּה בְּמַעֲשֵׂה

רשות הון ציבורי (RHF)

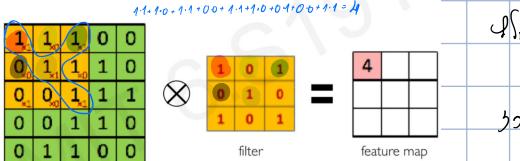
תְּמִימָנָה וְבָנָה - תְּמִימָנָה וְבָנָה

- تجربة (الجي) -

۱۷۱

- חסוך גזיניט (לעומת חשמל גז) הינו מושג נקי ויעיל.

המקרה הראשון (ב) מושג באמצעות פונקציית convolution (הסומן בצהוב). על מנת להבין מה שקרה, נזכיר את הפעולה של convolution על מatriceים:



ReLU  $\text{ReLU}(x) = \max\{0, x\}$  : ReLU-Activation 



Max Pooling Filter (2,2), stride 2

1	1	2	4
5	6	7	8
3	2	1	0
1	2	3	4

6	8
3	4

## Convolutional Neural Network



በዚህ የዚያወጪ መሠረት : CNN For Classification ✗

(ג) אם נסמן  $x$  כערך המינימום של  $f(x)$ , אז  $f(x) \geq x$ .

$$v_i = \frac{e^{y_i}}{\sum_j e^{y_j}}$$

וְכָל־עַמּוֹדֵה בְּבִירְתָּהוּ

הנתקן גורן מילר וויליאם ג'ון סטנלי

Table 1. Summary of the main characteristics of the four groups of patients.

softmax( $y_i$ ) =  $\frac{e^{y_i}}{\sum_j e^{y_j}}$

# Support Vector Machine (SVM)

